ESCOLA SUPERIOR DE TECNOLOGIA – EST

COORDENAÇÃO/CURSO: Sistemas de Informação	
PROFESSOR (A): Márcio Palheta Piedade, D.Sc.	
DISCIPLINA: Ciência de Dados 1	**PERÍODO LETIVO**: 2026/02

Trabalho Prático TP1 – Individual

Objetivo:

Realizar uma análise exploratória de duas bases reais, aplicando os recursos estudados: DataFrames, leitura de arquivos, seleção, filtros, indexação, estatísticas e visualização. Esses tópicos correspondem diretamente ao conteúdo trabalhado no material da disciplina.

Entrega: 19/10

Defesas: 20 e 22/10.

Base 1 — Netflix Movies and TV Shows

Netflix Movies and TV Shows — Kaggle:
https://www.kaggle.com/datasets/shivamb/netflix-shows

A base contém mais de 8 mil registros de filmes e séries, com atributos como tipo, título, diretor, elenco, país, ano de lançamento, classificação e duração.

1. Conhecendo e preparando os dados — 1,0 ponto

Utilizando Pandas:

1. Carregue o arquivo CSV.
2. Informe a quantidade de linhas e colunas.
3. Apresente as 5 primeiras e 5 últimas linhas.
4. Liste as colunas existentes.
5. Apresente os tipos de dados.
6. Identifique a quantidade de valores ausentes por coluna.
7. Verifique a existência de registros duplicados.
8. Utilize describe() e/ou outros métodos adequados para apresentar uma descrição inicial da base.
9. Explique, em texto, pelo menos 3 características ou problemas encontrados nos dados.

2. Investigação dos dados — 1,2 ponto

Utilizando operações do Pandas, responda:

1. Quantos registros correspondem a Movies e quantos a TV Shows?
2. Quais são os 10 países com maior quantidade de produções?
3. Quais são os 10 diretores com maior quantidade de produções?
4. Quais são as 5 classificações (rating) mais frequentes?
5. Quantas produções foram lançadas em cada ano?
6. Qual década apresenta a maior quantidade de títulos?
7. Considerando somente filmes, quais são as 10 durações mais frequentes?
8. Qual é o filme mais antigo da base? E o mais recente?

Cada questão deve apresentar **código, resultado e uma breve interpretação**.

3. Visualização dos dados — 0,8 ponto

Produza pelo menos 4 gráficos utilizando Matplotlib:

- quantidade de Movies × TV Shows;
- Top 10 países com mais produções;
- quantidade de títulos por ano;
- um gráfico de livre escolha.

Todos os gráficos devem apresentar:

- título;
- identificação dos eixos;
- legenda, quando necessária;
- tamanho e apresentação que permitam boa leitura.

Base 2 — Students Performance in Exams

[Students Performance in Exams — *https://www.kaggle.com/spscientist/students-performance-in-exams*

A base possui notas de Matemática, Leitura e Escrita, além de atributos como gênero, grupo, escolaridade dos pais, tipo de alimentação e realização ou não de curso preparatório.

4. Conhecendo e preparando os dados — 1,0 ponto

Realize:

1. carga do CSV;
2. head() e tail();
3. quantidade de linhas e colunas;
4. identificação dos tipos das colunas;
5. verificação de valores ausentes;
6. identificação de registros duplicados;
7. describe();
8. média e mediana das três notas.

Explique pelo menos 3 informações relevantes obtidas por meio do describe().

5. Análise do desempenho dos estudantes — 1,5 ponto

Utilizando Pandas:

1. Determine a média das notas de Matemática, Leitura e Escrita.

2. Determine a mediana de cada disciplina.

3. Identifique qual disciplina possui a maior média.

4. Crie uma nova coluna chamada media_geral, contendo a média das três notas.

5. Identifique os 10 estudantes com maior média geral.

6. Considerando média ≥ 70 como aprovação, determine o percentual de estudantes aprovados.

7. Compare a média geral por gênero.

8. Compare a média dos alunos que completaram o curso preparatório com aqueles que não completaram.

9. Determine a média geral por nível de escolaridade dos pais.

10. Identifique o grupo (race/ethnicity) com maior média geral.

Neste momento da disciplina, não é necessário realizar testes de hipótese. As conclusões devem ser baseadas na análise descritiva dos dados.

6. Visualização dos dados — 1,0 ponto

Construa pelo menos 5 gráficos com Matplotlib;

1. distribuição das notas de Matemática;
2. comparação das médias de Matemática, Leitura e Escrita;
3. média geral por gênero;
4. média dos estudantes com e sem curso preparatório;
5. um gráfico de livre escolha que apresente alguma descoberta interessante.

Cada gráfico deverá ser acompanhado de uma interpretação textual.

7. Investigação livre — 1,0 ponto

Esta parte deverá demonstrar maior autonomia do aluno.

Para cada uma das duas bases, formule duas perguntas próprias, diferentes das questões anteriores.

Portanto, serão 4 perguntas de investigação.

Para cada pergunta:

Pergunta → seleção/tratamento dos dados → análise com Pandas → gráfico com Matplotlib → conclusão.

Exemplos apenas para ilustrar o tipo de pergunta:

- A participação de determinados países no catálogo da Netflix mudou ao longo das décadas?
- O efeito aparente do curso preparatório é semelhante nas três disciplinas?
- As perguntas propostas pelo aluno também serão avaliadas. Perguntas excessivamente simples, cuja resposta seja apenas uma contagem direta, terão pontuação menor.

8. Conclusões — 0,5 ponto

O notebook deverá terminar com uma seção denominada **Conclusões**, contendo:

- pelo menos 3 descobertas relevantes sobre a Netflix;
- pelo menos 3 descobertas sobre desempenho dos estudantes;
- quais características das bases dificultaram as análises;
- qual das duas bases permitiu análises mais interessantes e por quê;
- limitações das análises realizadas.

Distribuição dos 8,0 pontos – Notebook

Etapa	Pontos
1. Netflix — preparação	1,0
2. Netflix — investigação	1,2
3. Netflix — gráficos	0,8
4. Estudantes — preparação	1,0
5. Estudantes — investigação	1,5
6. Estudantes — gráficos	1,0
7. Investigação livre	1,0
8. Conclusões	0,5
TOTAL	**8,0**

Nota de defesa: de 0 a 1,0

Nota Final: $notebook * defesa$